

**Sistema de Clasificación Automática de Tipos de Movimiento Oscilatorio
Simple y Amortiguado Mediante Reconocimiento de Imágenes con Deep
Learning, Como Apoyo al Aprendizaje**

Ángel Gabriel Burbano Rodríguez

Juan Felipe Arbeláez Osorio

Facultad de Ingenierías, Universidad Tecnológica de Pereira

CB434: Física III

Ing. Sebastián Velásquez Bonilla

02 de noviembre de 2025

Resumen

El Movimiento Armónico Simple (MAS) y el Movimiento Oscilatorio Amortiguado (MOA) presentan desafíos significativos, específicamente la dificultad de los estudiantes para relacionar las representaciones gráficas con sus respectivas ecuaciones. El MAS es un modelo ideal, el cual mantiene una amplitud constante a lo largo del tiempo, mientras que el MOA es más realista, ya que presenta un decaimiento exponencial de su amplitud debido a fuerzas disipativas.

Este proyecto propone el desarrollo de un Sistema de Clasificación Automática mediante técnicas de Deep Learning como una herramienta innovadora de apoyo al aprendizaje. El objetivo principal es implementar un clasificador de imágenes automático basado en Redes Neuronales Convolucionales (CNN) capaz de diferenciar entre ambos tipos de movimiento oscilatorio a partir de sus representaciones gráficas.

La metodología incluye la generación de un conjunto de datos sintéticos de aproximadamente 500 imágenes mediante Python, representando las ecuaciones teóricas del MAS $x(t) = A \cos(\omega t + \varphi)$ y del MOA $x(t) = Ae^{-\frac{b}{2m}t} \cos(\omega_d t + \varphi)$ con parámetros aleatorizados. El entrenamiento del modelo se realizará haciendo uso de la herramienta Teachable Machine de Google.

Adicionalmente, se desarrollará un módulo de cálculo interactivo que permitirá al estudiante ingresar parámetros iniciales y visualizar cómo estos determinan el comportamiento del movimiento oscilatorio, proporcionando retroalimentación instantánea. Se espera alcanzar una precisión de clasificación superior al 90 %, verificando así la efectividad del sistema como herramienta de apoyo al aprendizaje de la física de oscilaciones.

Palabras clave: Movimiento Armónico Simple, Movimiento Oscilatorio Amortiguado, Deep Learning, Redes Neuronales Convolucionales, Reconocimiento de Imágenes, Teachable Machine, Apoyo al Aprendizaje, Física de Oscilaciones

Abstract

Understanding Simple Harmonic Motion (SHM) and Damped Oscillatory Motion (DOM) presents significant challenges, specifically students' difficulty in connecting graphical representations with their respective equations. SHM is an ideal model, which maintains a constant amplitude over time, whereas DOM is more realistic, featuring an exponential decay of its amplitude due to dissipative forces.

This project proposes the development of an Automatic Classification System using Deep Learning techniques as an innovative learning support tool. The main objective is to implement an automatic image classifier based on Convolutional Neural Networks (CNN) capable of differentiating between both types of oscillatory motion based on their graphical representations.

The methodology includes the generation of a synthetic dataset of approximately 500 images using Python, representing the theoretical equations for SHM $x(t) = A \cos(\omega t + \varphi)$ and DOM $x(t) = Ae^{-\frac{b}{2m}t} \cos(\omega_d t + \varphi)$ with randomized parameters. The model will be trained using Google's Teachable Machine tool.

Additionally, an interactive calculation module will be developed that will allow the student to input initial parameters and visualize how these determine the behavior of the oscillatory motion, providing instant feedback. A classification accuracy exceeding 90% is expected to be achieved, thus verifying the system's effectiveness as a support tool for learning the physics of oscillations.

Keywords: Simple Harmonic Motion, Damped Oscillatory Motion, Deep Learning, Convolutional Neural Networks, Image Recognition, Teachable Machine, Learning Support, Oscillation Physics

Introducción

Contextualización del Problema

El Movimiento Armónico Simple (MAS) y el Movimiento Oscilatorio Amortiguado (MOA) constituyen pilares fundamentales en el estudio de la física de oscilaciones, con aplicaciones que abarcan desde sistemas mecánicos simples hasta fenómenos complejos en ingeniería estructural, electrónica y acústica (Serway & Beichner, 2002). El MAS representa un modelo idealizado, donde la amplitud permanece constante a lo largo del tiempo, mientras que el MOA representa sistemas físicos reales donde fuerzas disipativas, como la fricción, causan un decaimiento exponencial de la amplitud.

Desde un punto de vista pedagógico, la enseñanza de estos conceptos presenta desafíos significativos. Los estudiantes se enfrentan a dificultades conceptuales entre las representaciones visuales y las ecuaciones matemáticas. La metodología tradicional de enseñanza frecuentemente no proporciona la retroalimentación inmediata ni la interactividad para comprender estos conceptos efectivamente.

La dificultad está en el momento en el que los estudiantes deben, de manera simultánea, comprender conceptualmente el fenómeno físico, el dominio matemático y la interpretación visual. Esto puede dificultar el aprendizaje significativamente.

Justificación

En los últimos años, la inteligencia artificial (IA) y, específicamente, las técnicas de Deep Learning han revolucionado múltiples campos del conocimiento, incluyendo el ámbito educativo. Las Redes Neuronales Convolucionales (CNN) han demostrado capacidades excepcionales en tareas de reconocimiento y clasificación de imágenes, alcanzando precisiones superiores al 95 % en dominios variados (LeCun et al., 2015).

Este proyecto tiene como finalidad proponer el desarrollo de un Sistema de Clasificación Automática como herramienta de apoyo al aprendizaje, partiendo de la diferenciación visual entre

el MAS y el MOA: constancia versus el decaimiento exponencial de la amplitud.

Se busca proporcionar a los estudiantes una herramienta interactiva que pueda:

- Proveer retroalimentación inmediata sobre la identificación del tipo de movimiento oscilatorio.
- Relacionar la conexión entre representaciones gráficas y conceptos físicos.
- Experimentar escenarios.
- Facilitar el aprendizaje autónomo.

Objetivos del Proyecto

Objetivo General

Desarrollar e implementar un sistema de clasificación automática, basado en técnicas de Deep Learning y reconocimiento de imágenes, capaz de diferenciar entre representaciones gráficas de movimientos oscilatorios simples y amortiguados, como herramienta de apoyo innovadora al aprendizaje de la física de oscilaciones.

Objetivos Específicos

Fundamentación teórica Fundamentar teóricamente las ecuaciones, soluciones analíticas y gráficas que definen ambos movimientos oscilatorios.

Generación de datos Diseñar e implementar un algoritmo de generación de datos sintéticos que genere al menos 500 imágenes de ambos tipos de movimiento oscilatorio con variabilidad en los parámetros físicos relevantes (amplitud, frecuencia angular, ángulo de desfase y coeficiente de amortiguamiento).

Entrenamiento del modelo Entrenar un modelo de clasificación basado en Redes Neuronales Convolucionales (CNN) utilizando la plataforma Teachable Machine de Google.

Validación del sistema Validar el correcto funcionamiento del sistema mediante pruebas con imágenes de prueba desconocidas por el modelo en su etapa de entrenamiento, estableciendo como criterio de éxito una precisión de clasificación superior al 90 %.

Módulo interactivo Desarrollar un módulo interactivo que permita calcular las ecuaciones cinemáticas del MAS y del MOA, permitiendo a los estudiantes ingresar condiciones iniciales y visualizar resultados numéricos como la interpretación física de los mismos.

Integración Integrar ambos componentes (clasificador y calculadora) en una interfaz accesible que facilite su uso como herramienta de ayuda para el aprendizaje.

Marco Teórico

Movimiento Armónico Simple (MAS)

El movimiento armónico simple es un tipo particular de movimiento repetitivo, el cual es exhibido por un péndulo o un objeto sólido en un resorte. El capítulo 5 introdujo la fuerza de un resorte, la cual es descrita por la ley de Hooke: la fuerza del resorte es proporcional al desplazamiento del resorte a partir del equilibrio. La fuerza del resorte es una fuerza restauradora, siempre apuntando hacia la posición de equilibrio y es, de esta forma, opuesta en dirección al vector de desplazamiento:

$$F_x = -kx \quad (1)$$

La constante de proporcionalidad k se llama constante elástica (Bauer & Westfall, 2014, p. 483).

Ecuación de Movimiento (Ecuación Diferencial)

Para hallar la ecuación de movimiento, aplicamos la Segunda Ley de Newton ($F_x = ma$) a la fuerza de Hooke:

$$ma = -kx \quad (2)$$

Podemos despejar la aceleración a :

$$a = \frac{-kx}{m} \quad (3)$$

Sabemos que la aceleración, por definición, es la segunda derivada de la posición $x(t)$ con respecto al tiempo ($a = d^2x/dt^2$). Podemos escribir la ecuación diferencial de segundo orden del MAS:

$$\frac{d^2x}{dt^2} = \frac{-kx}{m} \quad (4)$$

Esta ecuación establece la condición cinemática clave del MAS: el movimiento es armónico simple únicamente si se cumple que su aceleración es directamente proporcional y de signo opuesto a su desplazamiento desde el equilibrio.

Solución de la Ecuación de Movimiento

Buscamos una función $x(t)$ cuya segunda derivada sea ella misma multiplicada por una constante negativa. Las funciones sinusoidales (seno y coseno) cumplen este requisito. Proponemos una solución de la forma $x(t) = A \cos(\omega t)$ (usando A para la amplitud, en reemplazo de r).

$$\Theta = \omega t \quad (5)$$

$$A = r \quad (6)$$

$$x = r \cos(\Theta) \quad (7)$$

Para verificar esta solución, la derivamos dos veces con respecto al tiempo:

$$x(t) = r \cos \Theta \rightarrow x(t) = r \cos(\omega t) \quad (8)$$

$$v(t) = \frac{dx}{dt} = -r \sin \Theta \rightarrow v(t) = \frac{dx}{dt} = -\omega r \sin(\omega t) \quad (9)$$

$$a(t) = \frac{d^2x}{dt^2} = -\omega^2 r \cos(\Theta) \rightarrow a(t) = \frac{d^2x}{dt^2} = -\omega^2 r \cos(\omega t) \quad (10)$$

Si observamos la expresión de la aceleración, podemos decir que:

$$a(t) = \frac{d^2x}{dt^2} = \frac{-kx}{m} \quad (11)$$

$$a(t) = \frac{d^2x}{dt^2} = -\omega^2 r \cos(\omega t) \quad (12)$$

Igualando ambas expresiones:

$$-\omega^2 x = \frac{-kx}{m} \rightarrow \omega^2 = \frac{k}{m} \quad (13)$$

$$\omega = \sqrt{\frac{k}{m}} \quad (14)$$

Cinemática del MAS

La solución general, que incluye una fase inicial φ para tener en cuenta las condiciones iniciales, nos permite describir la cinemática completa del movimiento.

Función del coseno.

$$x(t) = A \cos(\omega t + \varphi) \quad (15)$$

$$v(t) = -\omega A \sin(\omega t + \varphi) \quad (16)$$

$$a(t) = -\omega^2 A \cos(\omega t + \varphi) \quad (17)$$

Función del seno.

$$x(t) = A \sin(\omega t + \varphi) \quad (18)$$

$$v(t) = \omega A \cos(\omega t + \varphi) \quad (19)$$

$$a(t) = -\omega^2 A \sin(\omega t + \varphi) \quad (20)$$

De estas ecuaciones, podemos identificar los valores máximos:

$$v_{max}(t) = \omega A \quad (21)$$

$$a_{max}(t) = \omega^2 A \quad (22)$$

El movimiento es periódico. Las relaciones entre la frecuencia angular ω , el periodo T y la frecuencia f son:

$$f = \frac{\text{número de vueltas}}{\text{tiempo}} = \frac{\omega}{2\pi} = \frac{1}{T} \quad (23)$$

$$T = \frac{\text{tiempo}}{\text{número de vueltas}} = \frac{1}{f} = \frac{2\pi}{\omega} \quad (24)$$

$$\omega = \frac{2\pi}{T} = 2\pi f \quad (25)$$

Determinación de Amplitud y Fase (Condiciones Iniciales)

Las constantes A (amplitud) y φ (fase) no son propiedades del sistema, sino que se determinan por las condiciones iniciales del mismo.

Para hallar el ángulo de desfase φ :

$$x_o = A \cos(\varphi) \quad (26)$$

$$v_o = -\omega A \sin(\varphi) \quad (27)$$

$$\frac{v_o}{x_o} = \frac{-\omega A \sin(\varphi)}{A \cos(\varphi)} = -\omega \tan(\varphi) \quad (28)$$

$$\frac{-v_o}{x_o \omega} = \tan(\varphi) \quad (29)$$

$$\varphi = \tan^{-1} \left(\frac{-v_o}{\omega x_o} \right) \quad \text{solo se usa con función coseno} \quad (30)$$

Para la amplitud A :

$$x_o^2 = A^2 \cos^2(\varphi) \quad (31)$$

$$v_o^2 = \omega^2 A^2 \sin^2(\varphi) \rightarrow \frac{v_o^2}{\omega^2} = A^2 \sin^2(\varphi) \quad (32)$$

$$x_o^2 + \frac{v_o^2}{\omega^2} = A^2 \cos^2(\varphi) + A^2 \sin^2(\varphi) \quad (33)$$

$$x_o^2 + \frac{v_o^2}{\omega^2} = A^2 (\cos^2(\varphi) + \sin^2(\varphi)) \rightarrow (\cos^2(\varphi) + \sin^2(\varphi)) = 1 \quad (34)$$

$$A = \sqrt{x_o^2 + \frac{v_o^2}{\omega^2}} \quad (35)$$

Característica Fundamental: Conservación de la Energía

La característica fundamental del MAS es la conservación de la energía mecánica E . Al no haber fricción, la energía total permanece constante.

Energía potencial.

$$U = \frac{1}{2} k x^2 \rightarrow U = \frac{1}{2} k (A \cos(\omega t))^2 \quad (36)$$

Energía cinética.

$$K = \frac{1}{2}mv^2 \rightarrow K = \frac{1}{2}m(-\omega A \sin(\omega t))^2 \quad (37)$$

Energía total.

$$E = K + U \quad (38)$$

$$E = \frac{1}{2}m(-\omega A \sin(\omega t))^2 + \frac{1}{2}k(A \cos(\omega t))^2 \quad (39)$$

Teniendo en cuenta que $k = m\omega^2$, entonces:

$$E = \frac{1}{2}m\omega^2 A^2 \sin^2(\omega t) + \frac{1}{2}m\omega^2 A^2 \cos^2(\omega t) \quad (40)$$

$$E = \frac{1}{2}m\omega^2 A^2 (\sin^2(\omega t) + \cos^2(\omega t)) \quad (41)$$

Por identidad trigonométrica: $(\cos^2(\varphi) + \sin^2(\varphi)) = 1$, tenemos que:

$$E = \frac{1}{2}A^2k \quad \text{o} \quad E = \frac{1}{2}A^2m\omega^2 \quad (42)$$

Relación de Velocidad y Energía

Este principio de conservación de la energía nos permite encontrar una relación para la velocidad en función de la posición, eliminando la variable del tiempo:

$$\frac{1}{2}A^2k = \frac{1}{2}kx^2 + \frac{1}{2}mv^2 \quad (43)$$

Multipliquemos todo por 2 y despejamos v^2 :

$$A^2k = kx^2 + mv^2 \quad (44)$$

$$A^2k - kx^2 = mv^2 \quad (45)$$

$$\frac{k(A^2 - x^2)}{m} = v^2 \quad (46)$$

Sabemos que $\omega = \sqrt{k/m}$, entonces:

$$v = \sqrt{\frac{k(A^2 - x^2)}{m}} \quad (47)$$

$$v = \pm \omega \sqrt{A^2 - x^2} \quad (48)$$

Movimiento Oscilatorio Amortiguado

Ahora introducimos la complejidad del mundo real. El movimiento oscilatorio amortiguado ocurre cuando, además de la fuerza restauradora ($F_x = -kx$), existe una fuerza disipativa o de “fricción” F_d . Comúnmente, esta fuerza es proporcional a la velocidad y se opone a ella (Bauer & Westfall, 2014):

$$F_d = -bv \quad (49)$$

Donde b es el coeficiente de amortiguamiento.

Ecuación de Movimiento (Ecuación Diferencial)

Aplicamos la Segunda Ley de Newton con ambas fuerzas:

$$\sum F = F_r + F_d = ma \quad (50)$$

$$-kx - bv = ma \quad (51)$$

Reordenando, obtenemos la Ecuación Diferencial del Movimiento Oscilatorio Amortiguado:

$$m \frac{d^2x}{dt^2} + b \frac{dx}{dt} + kx = 0 \quad (52)$$

Solución de la Ecuación

Para resolver esta ecuación diferencial homogénea, proponemos una solución tipo “ansatz”:

$$x(t) = e^{\lambda t} \quad (53)$$

Sustituyendo esto y sus derivadas ($\frac{dx}{dt} = \lambda e^{\lambda t}$, $\frac{d^2x}{dt^2} = \lambda^2 e^{\lambda t}$) en la ecuación diferencial:

$$e^{\lambda t} (m\lambda^2 + b\lambda + k) = 0 \quad (54)$$

Esto debe ser cierto para todo t , por lo que el término entre paréntesis (la ecuación característica) debe ser cero:

$$m\lambda^2 + b\lambda + k = 0 \quad (55)$$

Las soluciones para λ se encuentran usando la fórmula cuadrática. La naturaleza de la solución (y por tanto, del movimiento) depende del discriminante ($b^2 - 4mk$) (Serway & Beichner, 2002, p. 368):

1. **Sobreamortiguado** ($b^2 - 4mk > 0$): Dos raíces reales y negativas λ . El sistema no oscila, simplemente regresa lentamente al equilibrio.
2. **Amortiguamiento crítico** ($b^2 - 4mk = 0$): Una raíz real negativa. El sistema regresa al equilibrio lo más rápido posible sin oscilar.
3. **Subamortiguado** ($b^2 - 4mk < 0$): Dos raíces complejas. Este es el caso que nos interesa para este proyecto, ya que es el único que oscila.

Caso Sobrearmortiguado

En este régimen, el discriminante es positivo y, por tanto, existen dos raíces reales y negativas, r_1 y r_2 . La solución general del desplazamiento está dada por:

$$x(t) = C_1 e^{r_1 t} + C_2 e^{r_2 t} \quad (56)$$

Dado que ambas raíces son negativas, el sistema no presenta oscilaciones, sino que retorna lentamente a la posición de equilibrio. El movimiento es monótono y la energía mecánica se disipa rápidamente en forma de calor (Serway & Beichner, 2002, p. 369).

Caso Críticamente Amortiguado

Cuando el discriminante es igual a cero, las dos raíces de la ecuación característica coinciden:

$$r_1 = r_2 = -\frac{b}{2m} \quad (57)$$

y la solución general adopta la forma:

$$x(t) = (C_1 + C_2 t) e^{-\frac{b}{2m} t} \quad (58)$$

El amortiguamiento crítico representa el límite entre los regímenes oscilatorio y no oscilatorio. En este caso, el sistema retorna al equilibrio en el menor tiempo posible sin oscilar (Serway & Beichner, 2002, p. 370).

Caso Subamortiguado

Si el discriminante es negativo, las raíces son complejas conjugadas y se pueden expresar como:

$$r = -\frac{b}{2m} \pm i\omega_d \quad (59)$$

donde:

$$\omega_d = \sqrt{\frac{k}{m} - \left(\frac{b}{2m}\right)^2} \quad (60)$$

es la frecuencia angular amortiguada, menor que la frecuencia natural del sistema $\omega_0 = \sqrt{k/m}$.

La solución general del desplazamiento resulta:

$$x(t) = e^{-\frac{b}{2m}t} (C_1 \cos(\omega_d t) + C_2 \sin(\omega_d t)) \quad (61)$$

Al combinar los términos seno y coseno en una sola función con fase, se obtiene:

$$x(t) = Ae^{-\frac{b}{2m}t} \cos(\omega_d t + \varphi) \quad (62)$$

Este caso corresponde al movimiento oscilatorio amortiguado y se caracteriza por la presencia de oscilaciones cuya amplitud decrece exponencialmente con el tiempo (Serway & Beichner, 2002, p. 371).

Deep Learning

Es una de las ramas del aprendizaje automático (Machine Learning) que utiliza redes neuronales artificiales con múltiples capas para modelar representaciones jerárquicas de los datos.

A comparación de los algoritmos tradicionales, las redes profundas son capaces de extraer automáticamente características complejas usando grandes cantidades de información.

El principio fundamental del aprendizaje profundo es la aproximación de funciones: una red neuronal intenta aprender la relación entre las entradas y salidas ajustando los pesos sinápticos mediante el proceso de retropropagación (backpropagation) (Kelleher, 2019).

Redes Neuronales Convolucionales (CNN)

Son un tipo especializado de red neuronal profunda, diseñada para procesar datos con estructura cuadriculada, como las imágenes.

Su arquitectura se compone principalmente de capas convolucionales, de agrupamiento (pooling) y completamente conectadas, las cuales trabajan en conjunto para detectar patrones espaciales y características jerárquicas.

En una capa convolucional, los filtros o kernels se deslizan sobre la imagen de entrada realizando operaciones de convolución, generando mapas de características que capturan bordes, texturas o formas específicas.

Posteriormente, las capas de pooling reducen la dimensionalidad, preservando la información más relevante, mientras que las capas densas o fully connected realizan la clasificación o regresión final (LeCun et al., 2015).

Metodología

Fase 1: Generación del Conjunto de Datos (Dataset)

El enfoque de esta fase será crear un conjunto de datos sintéticos diverso, ya que de esto depende la calidad de clasificación del modelo.

Generación de Datos

Dada la impracticidad de recolectar datos de manera manual, se desarrollará un script en Python, utilizando las librerías numpy, matplotlib y pathlib, para generar y guardar imágenes gráficas de ambos movimientos.

Etiquetado y organización. Las imágenes serán divididas en dos clases, una para cada movimiento oscilatorio (simple y amortiguado) que nuestro modelo de Machine Learning debe aprender:

- **Clase MAS:** Contendrá gráficas de $x(t) = A \cos(\omega t + \varphi)$
- **Clase MOA:** Contendrá gráficas de $x(t) = Ae^{-(\frac{b}{2m})t} \cos(\omega' t + \varphi)$

Con parámetros controlados.

Variabilidad. Para que el modelo de Machine Learning no se acostumbre a una misma tendencia, los parámetros de cada gráfica (amplitud, frecuencia, fase, constante de amortiguamiento) se seleccionarán aleatoriamente en cada imagen generada.

Fase 2: Diseño y Entrenamiento del Modelo con Teachable Machine

En lugar de programar una red neuronal desde cero, nos apoyaremos en la plataforma Teachable Machine.

Herramienta. Se utilizará Teachable Machine, una plataforma de Google diseñada para crear modelos de machine learning de forma fácil y rápida.

Proceso de configuración.

1. Se iniciará un nuevo “Proyecto de Imagen”.
2. Se crearán las dos clases requeridas: MAS y MOA.
3. Se subirán las imágenes generadas en la Fase 1 en sus respectivas clases.

Entrenamiento. Se iniciará el proceso de “Entrenar modelo” en Teachable Machine. La plataforma realiza una arquitectura de Redes Neuronales Convolucionales (CNN) y la entrenará con los datos sintéticos generados en la fase 1.

Fase 3: Validación del Enfoque

La plataforma Teachable Machine nos brinda herramientas para validar el modelo:

- **Nivel de precisión:** Con distintas imágenes, se verificará el correcto funcionamiento del modelo, buscando una excelente precisión.
- **Prueba:** Se cargarán imágenes de prueba, gráficas que el modelo no reconozca, esto para comprobar si la predicción del modelo es correcta.
- **Objetivo:** Se espera que el modelo alcance una precisión superior al 90% en la clasificación de nuevas imágenes, validando así el correcto funcionamiento del modelo.

Fase 4: Desarrollo e Implementación del Módulo de Cálculo

Esta fase se desarrollará en paralelo con el modelo de Machine Learning y se enfoca en el prototipo B:

- **Implementación de ecuaciones:** Se utilizará Python para realizar las soluciones de las ecuaciones del marco teórico.

- **Desarrollo de interfaz:** Se diseñará una interfaz de usuario con HTML, TAILWIND y JS en la cual el estudiante ingrese algunos valores conocidos para realizar el cálculo de los demás, mejorando así la comprensión de los temas académicos.
- **Validación de cálculos:** El sistema mostrará los resultados calculados junto a una explicación de los mismos. Se realizarán pruebas con valores conocidos para verificar que los cálculos sean correctos.

Diseño Conceptual y Prototipo Preliminar

Prototipo A

El diseño del sistema está basado en un enfoque de aprendizaje supervisado para clasificar imágenes. La arquitectura del sistema está diseñada para abstraer la complejidad física que pueden presentar las oscilaciones en características visuales que un modelo de Machine Learning pueda aprender a diferenciar.

Se propone un sistema que sigue un flujo de tres etapas principales:

1. Generación de Datos
2. Entrenamiento del modelo
3. Clasificación

Diseño Conceptual

Módulo de generación de datos sintéticos. Ya que la recolección de datos experimentales visuales reales es compleja, se opta por generar datos sintéticos, implementado en Python con las librerías Matplotlib y Numpy, hace uso de ecuaciones fundamentales del marco teórico para generar las gráficas sintéticas.

- **Clase MAS:** Contendrá gráficas de $x(t) = A \cos(\omega t + \varphi)$
- **Clase MOA:** Contendrá gráficas de $x(t) = A e^{-\left(\frac{b}{2m}\right)t} \cos(\omega' t + \varphi)$

La clave de este módulo es la generación de gráficas con aleatorización de parámetros (amplitud, frecuencia, fase, constante de amortiguamiento) para asegurarnos de que el modelo aprenda el patrón de movimiento y no un solo parámetro.

Módulo de entrenamiento. Para la realización del modelo de machine learning, se hará uso de la plataforma Teachable Machine de Google. Esta elección se debe a su capacidad de prototipado rápido, permitiendo de esta manera validar el enfoque conceptual sin la necesidad de desarrollar una Red Neuronal Convolucional desde cero.

Prototipo Preliminar

El prototipo preliminar consistirá en un modelo de clasificación de imágenes entrenado en la plataforma Teachable Machine.

- **Entradas del prototipo (dataset):** El conjunto de datos generado en la fase 1 de la Metodología.
- **Clases del prototipo:** El modelo será entrenado para diferenciar entre dos clases: MAS y MOA.
- **Interfaz del prototipo:** La interfaz de validación será la proporcionada por la plataforma Teachable Machine. Ya que nos permite cargar imágenes de prueba y devuelve una predicción instantánea.
- **Métrica de éxito:** El prototipo se considerará válido si alcanza una precisión de clasificación superior al 90 % en las pruebas.

A través de este diseño, podremos conectar directamente la teoría física con la herramienta de IA, cumpliendo el objetivo de crear un sistema de apoyo al aprendizaje.

Prototipo B

Adicionalmente, se desarrollará un módulo de cálculo interactivo. Este componente se enfoca en la aplicación cuantitativa de la teoría.

- **Propósito:** Permitir al estudiante comprender cómo las condiciones iniciales determinan las propiedades del movimiento.

- **Diseño:** Se implementará una herramienta que solicita al estudiante la entrada de parámetros conocidos.
- **Salida:** La herramienta utiliza las ecuaciones de la cinemática, demostradas en el marco teórico, para calcular y mostrar al estudiante los distintos cálculos realizados.

Resultados de los Cálculos Teóricos y Discusión Preliminares

Resultados de los Cálculos Teóricos

Movimiento Armónico Simple (MAS)

El Movimiento Armónico Simple (MAS) corresponde al caso ideal sin pérdidas de energía. Su ecuación diferencial, deducida de la segunda ley de Newton y la ley de Hooke, es:

$$m \frac{d^2x}{dt^2} + kx = 0$$

La solución general de esta ecuación diferencial es:

$$x(t) = A \cos(\omega t + \varphi)$$

donde:

- A es la amplitud máxima del desplazamiento,
- φ la fase inicial,
- ω la frecuencia angular del sistema.

Esto implica que la amplitud del movimiento no se modifica con el tiempo. Gráficamente, el MAS se representa mediante una onda sinusoidal de amplitud constante, lo que constituye su firma visual característica dentro del conjunto de datos que se usará para el entrenamiento del modelo de clasificación.

Movimiento Oscilatorio Amortiguado (MOA)

Cuando el sistema está sometido a una fuerza disipativa proporcional a la velocidad, la ecuación de movimiento se convierte en:

$$m \frac{d^2x}{dt^2} + b \frac{dx}{dt} + kx = 0$$

Para el caso subamortiguado (el único que presenta oscilaciones), la solución general es:

$$x(t) = A e^{-\frac{b}{2m}t} \cos(\omega_d t + \varphi)$$

Usando datos representativos, se puede observar que, como está en función de tiempo, esta amplitud irá disminuyendo a través del tiempo y, por tanto, habrá una disminución exponencial de la energía.

Ejemplo Numérico

Datos iniciales del sistema:

$$m = 1.0 \text{ kg}$$

$$k = 4.0 \text{ N/m}$$

$$b = 0.5 \text{ N}\cdot\text{s/m}$$

$$\varphi = 0.1 \text{ rad}$$

$$t = 0.5 \text{ s}$$

$$A = 0.5 \text{ m}$$

Movimiento Armónico Simple (MAS)

$$\omega = \sqrt{\frac{k}{m}} = \sqrt{\frac{4.0}{1.0}} = 2.0 \text{ rad/s} \quad (63)$$

$$\omega t + \varphi = 2.0(0.5) + 0.1 = 1.1 \text{ rad} \quad (64)$$

Posición en $t = 0.5 \text{ s}$:

$$x(t) = A \cos(\omega t + \varphi) \quad (65)$$

$$x(0.5) = 0.5 \cos(1.1) = 0.227 \text{ m} \quad (66)$$

Energía en $t = 0.5$ s:

$$E = \frac{1}{2}mA^2\omega^2 \quad (67)$$

$$E = \frac{1}{2}(1.0)(0.5)^2(2.0)^2 = 0.5 \text{ J} \quad (68)$$

Movimiento Oscilatorio Amortiguado (MOA)

$$\omega_0 = \sqrt{\frac{k}{m}} = 2.0 \text{ rad/s} \quad (69)$$

$$\omega_d = \sqrt{\frac{k}{m} - \left(\frac{b}{2m}\right)^2} = \sqrt{4 - \left(\frac{0.5}{2(1.0)}\right)^2} = 1.984 \text{ rad/s} \quad (70)$$

Posición en $t = 0.5$ s:

$$x(t) = Ae^{-\frac{b}{2m}t} \cos(\omega_d t + \varphi) \quad (71)$$

$$x(0.5) = 0.5e^{-0.25(0.5)} \cos(1.984(0.5) + 0.1) = 0.203 \text{ m} \quad (72)$$

Energía en $t = 0.5$ s:

$$E_0 = \frac{1}{2}kA^2 \quad (73)$$

$$E_0 = \frac{1}{2}(4.0)(0.5)^2 = 0.5 \text{ J} \quad (74)$$

$$E(t) = E_0 e^{-\frac{b}{2m}t} \quad (75)$$

$$E(0.5) = 0.5e^{-0.25} = 0.0389 \text{ J} \quad (76)$$

Estos valores demuestran de manera cuantitativa cómo el amortiguamiento modifica simultáneamente la amplitud y la energía del sistema, provocando una disminución exponencial tanto en la amplitud como en la energía.

Discusión Preliminar

Estos resultados apoyan la idea principal del proyecto: la diferencia entre ambos movimientos es física, matemática y visualmente distinguible, lo que permite su clasificación automática mediante técnicas de aprendizaje profundo.

El modelo de Deep Learning, basado en redes neuronales convolucionales (CNN), aprovechará precisamente esta diferencia:

- En el MAS: las imágenes muestran ondas simétricas y constantes.
- En el MOA: el patrón se caracteriza por un decaimiento progresivo de amplitud.

Durante la generación de los datos, estas ecuaciones se utilizaron para crear cientos de gráficos en Python, modificando aleatoriamente los parámetros A_0 , ω , φ y b .

Esto garantiza la diversidad del conjunto de entrenamiento y la validez física de las curvas que el modelo aprenderá a identificar.

Finalmente, se comprobó teóricamente que, al aumentar el coeficiente de amortiguamiento b , el sistema cambia desde el régimen oscilatorio subamortiguado hasta el críticamente amortiguado y sobreamortiguado (Serway & Beichner, 2002).

Conclusiones Iniciales

El desarrollo de la fundamentación teórica y el diseño conceptual del proyecto establecen las siguientes conclusiones preliminares:

- Se ha establecido un marco teórico robusto que define matemáticamente el Movimiento Armónico Simple (MAS) y el Movimiento Oscilatorio Amortiguado (MOA). Las ecuaciones que los rigen son distintas y conducen a comportamientos físicos y gráficos claramente diferenciados.
- La diferencia fundamental entre ambos movimientos se traduce en una característica visual inequívoca: la constancia o el decaimiento exponencial de la amplitud. Esta separabilidad visual es la hipótesis central que valida el enfoque de clasificación mediante IA.
- Se ha validado teóricamente la viabilidad de los dos prototipos propuestos. El Prototipo A (Clasificador) es viable debido a la distinción gráfica de las funciones. El Prototipo B (Calculadora) es viable ya que se basa en soluciones algebraicas derivadas de la teoría.
- El diseño metodológico propuesto, que combina la generación de datos sintéticos con el uso de herramientas de machine learning accesibles como Teachable Machine, es adecuado para cumplir con el objetivo general del proyecto: crear una herramienta de apoyo pedagógico funcional.

Referencias

- Bauer, W., & Westfall, G. D. (2014). *Física para ingeniería y ciencias*. McGraw-Hill/Interamericana.
- Kelleher, J. D. (2019). *Deep learning*. MIT Press. <https://doi.org/10.7551/mitpress/11171.001.0001>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Serway, R. A., & Beichner, R. J. (2002). *Física para ciencias e ingeniería*. McGraw-Hill.